Abilità Informatiche 2026/27

L03 · Strutturare i dati

Andrea Schimmenti · Università di Bologna

Di che cosa parliamo oggi

1. **Strutturare** ed **elaborare**
2. Le **strutture dati** fondamentali
3. Scrivere i dati: **CSV, JSON, XML**
4. I **linguaggi di marcatura**
5. I **grafi di conoscenza**
6. Dai testi ai dati: un accenno al **NLP**
7. Ogni struttura è una **scelta**

Filo conduttore: gli spaghetti **aglio, olio e peperoncino**.

1. Strutturare ed elaborare

Due cose che si fanno con i dati

Strutturare

organizzare secondo uno schema

→ **strutture dati**

→ **linguaggi di marcatura**

Elaborare

trasformare con una procedura

→ **algoritmi**

→ **linguaggi di programmazione**

La struttura decide quali operazioni sono **facili** e quali **difficili**: cercare in un elenco ordinato è facile, in uno disordinato no.

Oggi: **strutturare**. Elaborare: **L04**.

2. Le strutture dati

La lista

Sequenza **ordinata**; ogni elemento ha un **indice** (spesso da **0**).

```
versi = [ "Sempre caro mi fu quest'ermo colle,",
          "e questa siepe, che da tanta parte",
          "dell'ultimo orizzonte il guardo esclude." ]

versi[0]  →  "Sempre caro mi fu quest'ermo colle,"
versi[2]  →  "dell'ultimo orizzonte il guardo esclude."
```

Per tutto ciò che ha un **ordine**: parole di una frase, capitoli, cronologie. Ammette **duplicati**.

Il dizionario

Coppie **chiave** → **valore**; le chiavi sono **uniche**.

```
lemmi = { "corro":   "correre",
          "corsero": "correre",
          "andai":   "andare",
          "vado":    "andare",
          "uomini":  "uomo" }

lemmi["corsero"]  →  "correre"
```

Lemmatizzatori, glossari bilingui, indici dei nomi.

La tabella

Righe = oggetti · **colonne** = attributi. Fogli di calcolo, basi di dati.

id	autore	titolo	anno	lingua	genere
1	Giacomo Leopardi	L'infinito	1819	italiano	lirica
2	Alessandro Manzoni	I promessi sposi	1827	italiano	romanzo
3	Gustave Flaubert	Madame Bovary	1857	francese	romanzo
4	Rosalía de Castro	Cantares gallegos	1863	galiziano	lirica

Ogni colonna: **un solo tipo**, **un formato coerente** (`1827`, non "metà Ottocento").

L'albero

Struttura **gerarchica**: ogni nodo ha dei figli e un solo genitore (tranne la **radice**).

- la struttura di un'opera: cantiche → canti → terzine → versi
- le **cartelle** del computer
- l'**albero sintattico** di una frase
- la struttura di una **pagina web** *(L08)*

Il grafo

Nodi collegati da **archi**, senza gerarchia. Gli archi possono avere direzione ed etichetta.

- amicizie su un social network
- collegamenti tra pagine web
- corrispondenza tra intellettuali
- **relazioni tra i personaggi** di un romanzo

Renzo → promesso sposo di → Lucia · *Don Rodrigo → vuole impedire le nozze di → Lucia* · *Fra Cristoforo → protegge → Lucia*

Quale struttura scegliere

Struttura	Organizza	Domanda tipica	Esempio
Lista	sequenze	qual è il terzo?	parole di una frase
Dizionario	chiave → valore	qual è il valore?	forma → lemma
Tabella	oggetti con gli stessi attributi	quali righe...?	metadati di un corpus
Albero	gerarchie	che cosa contiene?	capitoli di un libro
Grafo	reti	come sono collegati?	personaggi

Nella realtà le strutture **si combinano**.

3. CSV, JSON, XML

La stessa informazione in tre formati

CSV

```
id,autore,titolo,anno
1,Giacomo Leopardi,L'infinito,1819
2,Alessandro Manzoni,I promessi sposi,1827
```

JSON

```
[ { "id": 1,
    "autore": "Giacomo Leopardi",
    "titolo": "L'infinito",
    "anno": 1819 } ]
```

XML

```
<testi>
  <testo id="1">
    <autore>Giacomo Leopardi</autore>
    <titolo>L'infinito</titolo>
    <anno>1819</anno>
  </testo>
</testi>
```

CSV: semplice, ma...

- valori con virgole → servono le **virgolette**
- in Italia Excel usa il **punto e virgola** → il file si apre tutto in una colonna altrove
- il file **non dichiara la codifica** → *mojibake* (L02)
- i fogli di calcolo "interpretano": una sigla può diventare una **data**

JSON: liste e dizionari, strutture annidate → lo standard per lo scambio tra applicazioni

XML: rappresenta naturalmente gli **alberi** → documenti, dizionari, `.docx`

4. I linguaggi di marcatura

Una pratica antica

- I redattori **annotavano a mano** i manoscritti: *corsivo*, *titolo*, *a capo*
- **Linguaggio di marcatura**: si inseriscono nel testo dei **tag** che ne descrivono struttura, significato o presentazione

Anno	
1986	**SGML**
1991	**HTML** (Tim Berners-Lee)
1998	**XML** (W3C)
2004	**Markdown** (questo sito è scritto così)

La sintassi di base

```
<titolo>L'infinito</titolo>                          <!-- elemento -->
<titolo lingua="it" tipo="principale">L'infinito</titolo>   <!-- attributi -->

<poesia>                                             <!-- annidamento -->
  <titolo>L'infinito</titolo>
  <testo>
    <verso n="1">Sempre caro mi fu quest'ermo colle,</verso>
  </testo>
</poesia>
```

- **Ben formato**: una radice, ogni tag chiuso, annidamento corretto, attributi tra virgolette
- **Valido**: rispetta uno **schema**

HTML e XML

HTML

- insieme **fisso** di elementi
- `<h1>`, `<p>`, `<a>`
- interpretato dal **browser**

XML

- **estensibile**: ognuno definisce i propri elementi
- es. la **TEI** per i testi:

```
<lg type="terzina">
  <l n="1">Nel mezzo del cammin…</l>
</lg>
```

Presentazione ("in corsivo") vs **descrittiva** ("titolo di un'opera", "parola straniera").

Esercizio 1: aglio, olio e peperoncino (15 minuti)

> Cuocete 320 g di spaghetti in abbondante acqua salata. In una padella scaldate 6 cucchiai di olio extravergine con 4 spicchi d'aglio a fettine e 1 peperoncino sminuzzato. Scolate al dente, tenendo un mestolo d'acqua, saltate in padella con una manciata di prezzemolo.

Strutturate in **XML** l'elenco degli **ingredienti**: quantità, unità, nome. I tag li inventate voi.

Come rappresentate *una manciata*? *abbondante*? Il **sale** senza quantità? E il *q.b.*?

5. I grafi di conoscenza

Le triple

soggetto → predicato → oggetto

Soggetto	Predicato	Oggetto
Giacomo Leopardi	è nato a	Recanati
Giacomo Leopardi	è autore di	L'infinito
L'infinito	fa parte di	Canti
L'infinito	ha come forma metrica	endecasillabo sciolto
Recanati	si trova in	Marche

Ogni tripla aggiunge un **arco**; il grafo si percorre **in ogni direzione**.

Wikidata è un grande grafo di conoscenza: oltre cento milioni di entità.

Classi, proprietà, identificativi

- Livello delle **asserzioni**: i fatti (*Leopardi è autore dell'Infinito*)
- Livello **terminologico** (**ontologia**): quali **classi** esistono (*Persona*, *Opera*, *Luogo*) e quali **proprietà** le collegano, con quali vincoli
- Ogni nodo ha un **identificativo univoco**: "Leopardi" è ambiguo, un identificativo no
- Istituzioni diverse che usano gli stessi identificativi → **Linked Open Data**

Esercizio 2: la ricetta come grafo (20 minuti)

Classi	Proprietà
Piatto, Ingrediente, Cucina, Metodo di cottura, Profilo aromatico	*contiene*, *appartiene alla cucina*, *si prepara con*, *ha sapore*, *si abbina a*

Scrivete almeno **dieci triple** per un piatto che sapete cucinare (o tipico della lingua che studiate) e disegnate il grafo.

Spaghetti AOP → contiene → aglio · → si prepara con → soffritto · peperoncino → ha sapore → piccante

Che cosa **non** riuscite a dire con queste proprietà?

6. Dai testi ai dati

Un accenno al NLP

La maggior parte dell'informazione è in **testi non strutturati**.

- **NER** (*Named Entity Recognition*): trova persone, luoghi, organizzazioni, date
- **Estrazione di relazioni**: trova le relazioni tra le entità → **triple**

> Giacomo Leopardi nacque a Recanati nel 1798. Nel 1822 si trasferì per alcuni mesi a Roma, ospite dello zio Carlo Antici. Dal 1833 visse a Napoli insieme all'amico Antonio Ranieri, e lì morì nel 1837.

Esercizio 3: sottolineate le entità, scrivete le triple. Chi è "lo zio" di chi? Che cosa indica "lì"?

7. Ogni struttura è una scelta

Il caso dei nomi di persona

Molti moduli: **nome** + **cognome**, il nome per primo. Ma:

- cinese, giapponese, coreano, ungherese: **prima il cognome**
- spagnolo e portoghese: spesso **due cognomi**
- islandese: un **patronimico** al posto del cognome
- in molte culture: **un nome solo**

E poi: *sesso* con due sole opzioni, *indirizzo* con via e numero civico, *lingua madre* con una sola scelta…

Che cosa succede a chi **non rientra nello schema**? E quando quei dati **addestrano un sistema automatico**?

Riassumendo

- **Strutturare** ed **elaborare** vanno insieme
- Cinque strutture: **lista**, **dizionario**, **tabella**, **albero**, **grafo**
- Per salvarle e scambiarle: **CSV**, **JSON**, **XML**
- **Marcatura**: tag, elementi, attributi; HTML fisso, XML estensibile
- **Grafi di conoscenza**: triple, classi, proprietà, identificativi
- Ogni struttura **include** qualcosa ed **esclude** qualcos'altro

Prossima lezione

L04 · Algoritmi e pensiero computazionale

Una ricetta per un robot, il plurale in Python, e perché l'ordine alfabetico non è uguale ovunque